

华中科技大学

本科生毕业设计（论文）开题报告

题目：基于梯度对齐的动态初始化策略在 LoRA 微调中的系统设计与实现

院 系 计算机科学与技术

专业班级 计科 2203

姓 名 张柏媚

学 号 U202215681

指导教师 万胜刚

2026 年 3 月

开题报告填写要求

一、 开题报告主要内容：

1. 课题来源、目的及意义；
2. 国内外研究现况及发展趋势；
3. 课题研究的内容和技术方案；
4. 可行性与风险分析；
5. 课题研究进度安排；
6. 主要参考文献。

二、 报告内容用小四号宋体字编辑，采用 A4 号纸双面打印，封面与封底采用浅蓝色封面纸（卡纸）打印。要求内容明确，语句通顺。

三、 指导教师评语、教研室（系、所）或开题报告答辩小组审核意见用蓝、黑钢笔手写或小四号宋体字编辑，签名必须手写。

四、 理、工、医类要求字数在 3000 字左右，文、管类要求字数在 2000 字左右。

五、 开题报告应在第八学期第二周之前完成。

1 课题来源、目的及意义

1.1 课题来源

随着大语言模型参数规模的指数级增长，从数十亿到数千亿参数，全量微调的计算成本与存储开销日益高昂^{[1][2]}。在此背景下，参数高效微调 PEFT 技术应运而生^[3]，其中以低秩自适应技术 LoRA^[4]为代表的方法通过引入低秩矩阵模块作为少量可训练参数，大幅降低了微调成本。

然而，标准 LoRA 在初始化阶段采用随机高斯初始化 A 矩阵、零初始化 B 矩阵的初始化策略，导致训练初期 A、B 矩阵的梯度更新方向与全量微调存在较大偏差，收敛速度较慢。针对这一问题，近期研究开始探索基于梯度对齐的初始化方法，如 LoRA-GA^[5]、LoRA-One^[6]等，通过利用第一步全梯度信息加速收敛。本课题正是在这一前沿研究方向的启发下提出。

1.2 课题目的及意义

本研究旨在设计一种基于梯度对齐的动态初始化策略，在现有梯度对齐方法的基础上引入动态子空间校准机制，进一步提升 LoRA 的收敛速度与最终性能。

具体目的包括：

- 建立梯度对齐初始化的数学理论框架，给出基于 SVD 分解的最优初始化方案；
- 设计周期性子空间校准方案，使 LoRA 适配器能够持续追踪梯度方向的动态演化，进一步加快收敛速度；
- 通过多任务实验验证该方法相比现有 LoRA 变体的优化效率；

本研究的意义在于：将动态校准机制引入梯度对齐框架，解决了静态初始化后期由于梯度子空间变化导致次优的问题，为 LoRA 的理论分析提供新视角。通过加速收敛、提升性能，可进一步降低大模型微调的计算成本，促进大模型在资源受限场景（如移动端、边缘设备）的落地应用。

2 国内外研究现状及发展趋势

2.1 LoRA 及其变体的研究现状

自 Edward Hu 等人于 2021 年提出 LoRA 以来，该领域涌现了大量改进工作。标准 LoRA 通过低秩分解 $W = W_0 + BA$ 来近似全量微调参数更新，其中 $B \in$

$R^{d \times r}, A \in R^{r \times k}$, 秩 $r \ll \min(d, k)$, 可训练参数减少 90% 以上。而一些实证实验证明^{[7][8][9]}, LoRA 虽然极大减少了参数数量, 但其收敛速度相比全量微调大大降低。在相同学习率下, 为了与全量微调达到相同的性能, LoRA 需要高达 5-6 倍的迭代次数以及 FLOPs^[10], 在总体上增加了计算开销甚至导致性能下降。

因此, 后续优化变体包括 AdaLoRA^[10]、DoRA^[11]等陆续出现, 分别在秩的动态分配调整和权重结构优化方面取得进展。

2.2 梯度对齐初始化研究进展

相关研究表明, 全量微调的梯度信息可用于优化 LoRA 的初始化策略。ICML 2025 spotlight 论文 LoRA-One 从理论上证明了: 在梯度下降下, LoRA 适配器会与全量微调一步梯度的特定奇异子空间对齐, 通过合理利用一步全梯度进行初始化, 可以立即实现子空间对齐。论文中实验表明, LoRA-One 在 GLUE、GSM8K、HumanEval 等任务上显著优于标准 LoRA; LoRA-GA 通过利用全量梯度的 SVD 分解近似进行初始化, 显著加速早期训练。

而现有梯度对齐方法普遍采用静态初始化策略, 仅利用第一步梯度信息, 但忽视了训练过程中梯度方向的动态演化。最新研究证实, 梯度在神经网络训练时会在一个低维子空间中演化^[12]。因此, 如何让 LoRA 适配器动态适应这种演化, 成为当前的重要研究趋势。

3 研究内容与技术方案

3.1 课题研究内容

本课题提出 GADI (Gradient-Aligned Dynamic Initialization) 策略, 在梯度对齐初始化基础上引入动态子空间校准机制, 使 LoRA 适配器持续追踪梯度演化, 解决静态初始化后期子空间次优的问题。

3.2 课题预期目标

课题预期通过在现有梯度对齐方法的基础上引入动态子空间校准机制, 解决静态初始化后期子空间次优的问题, 从而显著提升 LoRA 微调的收敛速度与最终性能, 并为 LoRA 方法的理论分析提供新的视角。

3.3 理论推导与算法流程

3.3.1 理论推导

GADI 的关键要素包含两个：（1）初始化阶段，近似全量微调的梯度下降方向，实现全量微调特定奇异子空间对齐；（2）动态校准阶段，周期性地对 A、B 模块进行旋转校准，保证 LoRA 梯度能够持续追踪梯度演化轨迹。

（1）初始化阶段

在初始化阶段的目标是：保证第一步的 LoRA 增量 $\Delta(\eta BA)$ 尽可能逼近全量微调第一步的增量 ΔW 。如式(1)所示，其中 ζ 为非零正数缩放常量。

$$\Delta(\eta BA) \approx \zeta \Delta W \quad (1)$$

考虑 A、B 模块的学习率为 λ ，则第一步训练后，A 和 B 各自的增量如式(2)所示，考虑学习率极其小，因此舍弃了二阶量。

$$\eta \left(B_0 + \lambda \frac{\partial L}{\partial B_0} \right) (A_0 + \lambda \frac{\partial L}{\partial A_0}) - \eta B_0 A_0 \approx \lambda \eta \left(B_0 \frac{\partial L}{\partial A_0} + \frac{\partial L}{\partial B_0} A_0 \right) \quad (2)$$

为了衡量 LoRA 增量与全量微调增量的近似程度，采用 Frobenius 范数作为衡量指标，则二者的差异程度如式(3)所示。

$$\left\| \lambda \eta \left(B_0 \frac{\partial L}{\partial A_0} + \frac{\partial L}{\partial B_0} A_0 \right) - \zeta \frac{\partial L}{\partial W_0} \right\|_F \quad (3)$$

由于完整权重 W 由原始冻结权重与 A、B 模块构成 $W' = W_0 + \eta BA$ ，根据链式求导法则，可以得到 B_0 的梯度如式(4)所示，同理可得 A_0 的梯度为 $\eta B^T \frac{\partial L}{\partial W'}$ 。

$$\frac{\partial L}{\partial B_0} = \frac{\partial L}{\partial W'} \times \frac{\partial W'}{\partial B_0} = \eta \frac{\partial L}{\partial W'} A^T \quad (4)$$

注意上式中，在训练起始时， $W' = W_0, A = A_0, B = B_0$ 。由此可得到式(3)的化简结果如下：

$$\left\| \lambda \eta^2 B_0 B_0^T \frac{\partial L}{\partial W_0} + \lambda \eta^2 \frac{\partial L}{\partial W_0} A_0^T A_0 - \zeta \frac{\partial L}{\partial W_0} \right\|_F \quad (5)$$

因此上述目标可以转化为最优解问题，问题描述：

$$\min_{A_0, B_0} \left\| \eta^2 B_0 B_0^T \frac{\partial L}{\partial W_0} + \eta^2 \frac{\partial L}{\partial W_0} A_0^T A_0 - \zeta \frac{\partial L}{\partial W_0} \right\|_F \quad (6)$$

假设对全量微调第一步的梯度 $\frac{\partial L}{\partial W_0}$ 进行 SVD 分解为 $U \Sigma V^T$ ，则上述问题的一组最优解如式(7)所示。 $U[r+1:2r]$ 表示取 U 的 $r+1 \sim 2r$ 列， $V^T[1:r]$ 表示取 V^T 的 $1 \sim r$ 行； r 为 LoRA 秩； η 为 LoRA 适配器的缩放因子，通常取值为 $\frac{\alpha}{\sqrt{r}}$ （ α 为超参数）；

ζ 为 LoRA-GA 用于稳定训练过程的稳定性因子, 取值为 $\frac{\alpha^2}{\gamma^2} \sqrt{\frac{d_{out}}{r^2}}$ (γ 为超参数), d_{out} 为输出维度。因此 A_0 、 B_0 前面的系数取值为 $\frac{\sqrt[4]{d_{out}}}{\gamma}$ 。

$$B_0 = \frac{\sqrt{\zeta}}{\eta} U[r + 1: 2r], A_0 = \frac{\sqrt{\zeta}}{\eta} V^T[1: r] \quad (7)$$

至此即可得到 A、B 模块各自的初始化值, 使得 LoRA 梯度尽可能逼近全量微调梯度, 加速收敛。

(2) 动态校准阶段

随着训练进行, 梯度方向会发生变化。在动态校准阶段, 周期性地对 A、B 模块进行旋转校准, 目的是使 LoRA 适配器的子空间与当前全量梯度的主方向对齐, 保证 LoRA 梯度能够持续追踪梯度演化轨迹。

假设校准周期为 T, 在某次迭代需要进行动态校准时, 采样一个小批量数据。假设当前冻结权重 W_0 , LoRA 适配器 A_t, B_t , 则当前有效权重为 $W_t = W_0 + B_t A_t$ 。利用小批量数据在当前有效权重上进行一轮正向传播和反向传播, 得到此时的全量微调梯度, 对其进行 SVD 分解得到 $U_t \Sigma V_t^T$ 。同前面的初始化阶段, 可以由左右奇异矩阵得到目标 LoRA 适配器 A'_t, B'_t 满足当前的 LoRA 梯度方向逼近全量微调的梯度方向。

接着利用一对互为转置的旋转矩阵 R, R^T , 对当前的 A、B 矩阵进行旋转操作如下:

$$B_{new} = B_t R, A_{new} = R^T A_t \quad (8)$$

上式中, R 为下面最优化问题的解:

$$\min_{Q Q^T = I} (\|B_t Q - B'_t\|_F + \|Q^T A_t - A'_t\|_F) \quad (9)$$

即 R 满足两个条件: (1) R 为正交矩阵; (2) R 的作用是将当前 A、B 的梯度子空间旋转到与当前全量微调梯度方向对齐。由于 R 为正交矩阵, 因此上述旋转操作保证了低秩更新矩阵不变, 即 $B_{new} A_{new} = B_t R R^T A_t = B_t A_t$, 从而保证了训练的稳定性。

3.3.2 算法流程

GADI 的完整算法流程图如图 1 所示。初始时加载预训练模型 W_0 , 并设置超参数。计算第一步全量微调的梯度 $G_0 = \frac{\partial L}{\partial W_0}$, 根据式(7)对 LoRA 适配器 A、B 进行初始化。接着开始 LoRA 训练过程, 每 T 步则计算当前全量微调梯度, 并根据

式(8)、式(9)对 A、B 进行旋转校准，直至收敛。




图 1 GADI 算法流程图

4 可行性与风险分析

4.1 制约因素与风险

大模型训练需要消耗大量计算资源，对环境造成一定压力。为践行绿色 computing 理念，本课题在实现过程中会遵循：第一，优化算法效率。本课题提出的 GADI 方案本身旨在加速收敛、减少训练步数，直接降低了训练过程中的能耗。动态校准机制虽然引入少量额外计算，但整体能耗相比标准 LoRA 仍显著降低；第二，实验资源集约使用。在实验设计中，优先使用小规模模型（如 RoBERTa-base）进行算法验证，待关键参数确定后再在 7B 级别模型上进行最终实验，最大限度减少不必要的计算资源消耗。

面临的 风险以及应对措施如表 1 所示。

表 1 风险因素及应对措施

风险因素	风险描述	应对措施
------	------	------

计算开销 风险	动态校准需要在每 T 步进行一次 SVD 分解和正交 Procrustes 求解。对于 7B 级别的大模型，单次 SVD 分解的计算开销可能达到数十秒，若校准周期过短，将显著增加训练时间。	一是通过实验确定最优校准周期 T ，在 $T \in \{50,100,200,500\}$ 范围内进行消融实验，找到性能与开销的最佳平衡点。二是仅对部分关键层进行校准，而非所有 LoRA 层。
超参数敏 感性风险	本方案引入了新的超参数校准周期 T ，其取值对性能有重要影响。若过小，频繁校准导致计算开销过大且可能引入振荡；若过大，则校准效果有限，退化为静态初始化。	将 T 作为可调超参数纳入实验设计，进行系统性的网格搜索。还可以考虑设计自适应校准策略，根据梯度变化速率动态调整校准频率。
实验验证 风险	大模型实验周期长、资源消耗大，一个完整的实验可能需要数天甚至数周时间。若前期设计存在疏漏，可能浪费大量计算资源且延误进度。	采用分层验证策略，在每次大规模实验前进行小规模预实验，确保代码正确性和参数合理性。

4.2 成本估算与可行性

在软件开发成本估算的诸多模型中，我选择基本 COCOMO 模型作为本课题的估算方法。原因在于 COCOMO 模型最初基于 2000-100000 行代码的项目研究得出，与本研究预期的代码规模相符合。

本课题的软件开发主要包括模块有：数据预处理模块、梯度计算模块、SVD 分解与初始化模块、动态校准模块、实验对比模块等。考虑到 Python 语言的简洁性以及现有 LoRA 库可复用，取源代码行数 $L = 3,500 \text{ LOC}$ 。

由于团队规模为单人开发，属于小型项目；无特殊硬件要求，依赖现有 GPU 资源；研究目标清晰，无频繁需求变更。因此本项目符合组织型项目的特征。

因此开发工作量 $MM = 0.4 \times 3.5^{1.05} = 1.5$ 人月，符合本科生毕业设计要求。

5 课题研究进度安排

由于本课题是一个研究性的课题，构思和实验的进度难以确定。大致的进度安排如表 2 所示。

表 2 课题研究进度安排表

周次	工作任务
第 1~2 周	深入理解 LoRA 及梯度对齐方法，阅读相关论文（LoRA、LoRA-GA、PiSSA 等），总结现有方法的优缺点，明确研究方向。完成参考文献翻译、开题报告。

第 3~5 周	搭建实验环境，基于 PyTorch 和 Hugging Face PEFT 库实现 GADI 方法，编写动态校准模块，进行代码调试和单元测试。
第 6~8 周	在多个数据集和模型上进行实验验证，与标准 LoRA、LoRA-GA、PiSSA 等方法进行对比，收集实验数据，分析结果。
第 9~11 周	撰写论文，完善实验结果和理论分析，准备毕业答辩。

6 主要参考文献

- [1] Alec Radford, Jeffrey Wu, Rewon Child, David Luan, Dario Amodei, and Ilya Sutskever. Language Models are Unsupervised Multitask Learners. pp. 24, b.
- [2] Tom B. Brown, Benjamin Mann, Nick Ryder, Melanie Subbiah, Jared Kaplan, Prafulla Dhariwal, Arvind Neelakantan, Pranav Shyam, Girish Sastry, Amanda Askell, Sandhini Agarwal, Ariel Herbert-Voss, Gretchen Krueger, Tom Henighan, Rewon Child, Aditya Ramesh, Daniel M. Ziegler, Jeffrey Wu, Clemens Winter, Christopher Hesse, Mark Chen, Eric Sigler, Mateusz Litwin, Scott Gray, Benjamin Chess, Jack Clark, Christopher Berner, Sam McCandlish, Alec Radford, Ilya Sutskever, and Dario Amodei. Language Models are Few-Shot Learners. arXiv:2005.14165[cs], July 2020. URL <http://arxiv.org/abs/2005.14165>.
- [3] Zeyu Han, Chao Gao, Jinyang Liu, Sai Qian Zhang, et al. Parameter-efficient fine-tuning for large models: A comprehensive survey. arXiv preprint arXiv:2403.14608, 2024.
- [4] Hu E, Shen Y, Wallis P, et al. LoRA: Low-Rank Adaptation of Large Language Models. ICLR 2021.
- [5] Shaowen Wang, Linxi Yu, Jian Li. LoRA-GA: Low-Rank Adaption with Gradient Approximation. arXiv 2024.
- [6] Zhang Y, Liu F, Chen Y. LoRA-One: One-Step Full Gradient Could Suffice for Fine-Tuning Large Language Models, Provably and Efficiently. ICML 2025 (Spotlight).
- [7] Ning Ding, Yujia Qin, Guang Yang, Fuchao Wei, Zonghan Yang, Yusheng Su, Shengding Hu, Yulin Chen, Chi-Min Chan, Weize Chen, et al. Parameter-efficient fine-tuning of large-scale pre-trained language models. Nature Machine Intelligence, 5(3):220–235, 2023.

- [8] Rui Pan, Xiang Liu, Shizhe Diao, Renjie Pi, Jipeng Zhang, Chi Han, and Tong Zhang. Lisa: Layerwise importance sampling for memory-efficient large language model fine-tuning, 2024.
- [9] Shih-Yang Liu, Chien-Yi Wang, Hongxu Yin, Pavlo Molchanov, Yu-Chiang Frank Wang, Kwang-Ting Cheng, and Min-Hung Chen. Dora: Weight-decomposed low-rank adaptation, 2024.
- [10] Qingru Zhang, Minshuo Chen, Alexander Bukharin, Nikos Karampatziakis, Pengcheng He, Yu Cheng, Weizhu Chen. AdaLoRA: Adaptive Budget Allocation for Parameter-efficient Fine-Tuning. arXiv 2023.
- [11] Shih-yang Liu, Chien-Yi Wang, Hongxu Yin, Pavlo Molchanov, Yu-Chiang Frank Wang, Kwang-Ting Cheng, Min-Hung Chen. DoRA: Weight-Decomposed Low-Rank Adaptation. ICML 2024.
- [12] Anherutowa Calvo. Predictable Gradient Manifolds in Deep Learning: Temporal Path-Length and Intrinsic Rank as a Complexity Regime. arXiv.

华中科技大学本科生毕业设计（论文）开题报告评审表

姓名	张柏媚	学号	U202215681	指导教师	万胜刚
院（系）专业	计算机科学与技术学院计科 2203				
指导教师评语 1. 学生前期表现情况。 2. 是否具备开始设计（论文）条件？是否同意开始设计（论文）？ 3. 不足及建议。					
该生前期表现积极认真，查阅了大量相关文献，对课题背景及国内外研究现状有较深入的理解。所撰写的开题报告方案合理、技术路线清晰，进度安排得当，研究内容饱满度与难度均符合本科毕业设计要求，具备了开展设计工作的理论基础与实践能力。同意开题，建议后续加强对核心算法的仿真验证，并对实验结果的预期做出更细致的分析。 评 分：88 指导教师（签名）：万胜刚 2026年3月13日					
教研室（系、所）或开题报告答辩小组审核意见					
同意开题 教研室（系、所）或开题报告答辩小组负责人（签名）：蔡海 年 月 日					